



HybridACD Giải mã Ràng buộc Đối nghịch

GVHD

TS. LƯU THANH SƠN






Link bài báo



Bài báo gốc



Bài báo chính



Tóm tắt nghiên cứu bài báo gốc

CONSISTENCY CHECKS FOR LARGE LANGUAGE MODEL

Bài báo đã định nghĩa một nhà dự báo F (Forecaster) từ không gian câu hỏi dự báo nhị phân P (Prop) vào khoảng $[0,1]$ để đo lường tính mức phạm logic với 10 quy tắc kiểm tra Logic:

- 1.Negation
- 2.Paraphrase
- 3.Consequence
- 4.AndOr
- 5.And
- 6.Or
- 7.But
- 8.Cond
- 9.CondCond
- 10.Expevidence

CONSISTENCY CHECKS FOR LANGUAGE MODEL FORECASTERS

Daniel Paleka *
ETH Zurich

Abhimanyu Pallavi Sudhir *
University of Warwick

Alejandro Alvarez
Independent

Vineeth Bhat
IIIT Hyderabad

Adam Shen
Columbia University

Evan Wang
Cornell University

Florian Tramèr
ETH Zurich



Số đo trọng tài thương mại (Arbitrage Metric)

$$V(F(x_1), \dots, F(x_n)) = \max_{p \in [0,1]^n} \min_{\omega \in \Omega} \sum_{i=1}^n \left(\log \frac{p_i}{F(x_i)} \delta_{\omega(i)=\top} + \log \frac{1-p_i}{1-F(x_i)} \delta_{\omega(i)=\perp} \right)$$

Số đo tần suất (Frequentist Metric)

$$F(P) - T(P) \sim \mathcal{N} \left(0, \sigma^2 T(P) (1 - T(P)) \right)$$

Cửa sổ ngữ cảnh



If forced to assign a number, the probability of a Portugal win is ~0.48, with a very high likelihood of the match going into extra time or penalties.

Will Portugal national football team defeat Spain in the round of 16, 2026 world cup?
give me probability from 0 -> 1

Cửa sổ ngữ cảnh khác



If you are looking for the overall likelihood of Spain ultimately defeating Portugal to reach the quarterfinals, 0.64 is the most accurate figure based on the current market consensus. [Squawka](#)

Will Portugal national football team be defeated from Spain in the round of 16, 2026 world cup?
give me probability from 0 -> 1

Bảng tóm tắt đặc điểm của các thước đo nhất quán


Số đo	Cách thức hoạt động	Ứng dụng	Ưu điểm	Nhược điểm
Số đo trọng tài thương mại (Arbitrage Metric)	Dựa trên lý thuyết "Dutch Book". Chuyển lỗi logic của AI thành bài toán kinh tế trên sàn dự báo, đo lường "số tiền lời ròng chắc chắn" tối đa mà tay buôn cơ hội (arbitrageur) kiếm được từ sự mâu thuẫn đó.	Dùng làm thước đo tức thời để chấm điểm AI thay cho kết quả tương lai. Làm hàm mục tiêu để chạy đệ quy sửa lỗi mô hình.	- Rất nhạy bén ở vùng xác suất biên (phạt nặng lỗi tự tin mù quáng). - Quy đổi mọi lỗi logic về một "đơn vị tiền tệ" chung để cộng dồn.	- Dễ dính bẫy Goodhart (mô hình lách luật bằng cách đoán 50%). - Phạt trực tiếp/đệ quy gây Overfitting và tổn kém khổng lồ (2500 USD/câu).
Số đo tần suất (Frequentist Metric)	Dựa trên giả lập Monte Carlo. Tính khoảng cách hình học ngắn nhất (qua L1 hoặc L2) từ dự báo gốc của AI đến một phân phối xác suất hợp lệ toán học gần nhất.	Làm thước đo đối chứng chuẩn hóa. Ứng dụng để kiểm định giả thuyết thống kê, đánh giá "nhiều tự nhiên" của mô hình.	- Phạt tuyến tính, bình ổn dựa trên khoảng cách tuyệt đối. - Cho phép mức dung sai ngẫu nhiên, không phạt các vi phạm siêu nhỏ.	- Kém nhạy bén ở vùng xác suất biên. - Phạt "cào bằng", không phân biệt được sự nguy hiểm giữa lỗi ở vùng 0.5 so với lỗi tự tin cực đoan 0.99.

HOME

ABOUT

CONTENT

OTHERS



Giới thiệu

INTRODUCTION

Công trình liên quan

RELATED WORKS

Phương pháp

METHOD

Kết quả

RESULTS

Kết luận

CONCLUSION






Chương 1


Giới thiệu

GVHD

TS. LƯU THANH SƠN



HybridACD: Giải mã Ràng buộc Đối nghịch
cho Dự báo Mô hình Ngôn ngữ Lớn Nhất quán
về Mặt Logic




Kiến trúc HybridACD

Adversarial Constraint Decoding

Là một giải pháp tối ưu hoá được tổng hợp dựa trên các nghiên cứu gần đây nhằm giải quyết triệt để sự đánh đổi giữa chi phí vận hành, độ chính xác dự báo và tính nhất quán logic của các siêu mô hình LLM


Khởi tạo Đối kháng

ADVERSARIAL INPUT
AGENT (AIG)



Ràng buộc giải mã toán học

TOKEN CONSTRAINT
DECODING - TCD
DECODING-TIME ALIGNMENT



HybridACD

ADVERSARIAL CONSTRAINT
DECODING





HybridACD là gì ?

*VIẾT LẠI ĐỐI KHÁNG VÀ GIẢI MÃ
RẰNG BƯỚC TOKEN*

- Không huấn luyện lại mô hình
- Không hiệu chỉnh lặp hậu nghiệm (đệ quy)
- Trực tiếp chuyển các quy tắc xác suất thành khoảng hợp lệ cho token đầu ra
- Ép mô hình phải tuân thủ các ràng buộc xác suất mà mô hình vẫn có thể tự do suy luận



HOME

ABOUT

CONTENT

OTHERS



Question Element: P

Question Title [P]

Will AAPL close above \$250.00 on 2026-12-31 (US market close)?

Resolution Criteria [P]

Resolves YES if Apple Inc. (AAPL) official closing price on 2026-12-31, as reported by Nasdaq Official Close (or, if unavailable, the primary listing exchange official close), is strictly greater

FINAL PROBABILITY: 0.1400





✓ Question Element: not_P

Question Title [not_P]

Will Apple Inc. (AAPL) fail to exceed \$1,000 per share at any time dur

Resolution Criteria [not_P]

Resolves YES if, for every trading day from 2030-01-01 through 2030-12-31 (inclusive), the official closing price (regular session) of AAPL common stock is less than or equal to 1000.00 USD, using the same primary source hierarchy as the paired question and the same split-adjustment rule. Resolves NO if AAPL's split-adjusted official close is strictly greater than 1000.00 USD on at least one trading day in 2030.



FINAL PROBABILITY: 0.8600




Chương 2

Công trình liên quan

GVHD

TS. LƯU THANH SƠN



Các công trình nghiên cứu liên quan sau đây có giải quyết được vấn đề mà bài báo gốc đang gặp phải hay không, liệu có một phương pháp nào đột phá?

Phương pháp cải tiến	Chi phí	Độ trễ	Tính khả thi	Kết luận và hạn chế
Forecaster Suy luận Từng bước (CoT Baseline)	\$0.05 - \$0.20	Chậm (tùy thuộc vào CoT sinh ra)	Mô hình vi phạm nghiêm trọng (lỗi ~58% ở quy tắc phủ định)	Làm chuẩn benchmark nhưng không phải là giải pháp triệt để
Tinh chỉnh Trọng số Trực tiếp (Training for Consistency)	\$5000 - \$10000	Rất nhanh (Trong số tĩnh, không cần đệ quy)	Đảm bảo hoàn hảo tính nhất quán nhưng dễ dính vào định luật Goodhart (đoán bừa để lách luật)	Đánh đổi Brier Score để lấy số liệu hình thức
Tối ưu hóa preference và self-consistency	\$0.05 - \$0.20	Chậm (tùy thuộc vào CoT sinh ra)	Vẫn ở trong giai đoạn nội tại hoặc chọn mẫu	Khả thi thấp
Controlled prompting và độ bền đối nghịch	\$0.10 - \$0.25	Nhanh (Trong số tĩnh, không cần đệ quy)	giảm các câu trả lời không nhất quán giữa những truy vấn tương đương	Có tính khả thi nhưng chưa tối
Thuật toán Trọng tài Đệ quy (ArbitrageForecaster r=4)	~ \$2,500.00	Cực Chậm (đệ quy nhiều do hội chéo API)	Tối ưu hoá tốt những rất dễ bị overfitting, làm lỗi ở quy tắc chéo và giảm Brier Score	Chi phí quá lớn
Can thiệp Giải mã Toán học (Token Constraint Decoding - TCD)	\$0.05 - \$0.25	Trung bình	Dễ dàng cắt đứt lỗi tự tin thái quá của model bằng cách chặn logit nhưng quá trình suy luận CoT ở các bước đầu vẫn hoạt động tự do	Khả thi cao, sử dụng các mô hình mở hoặc API cho phép can thiệp logit
Kiến trúc Hybrid ACD (Adversarial Agent + Constraint Decoding)	\$0.15 - \$0.50	Trung bình + chậm	Hoàn hảo ở mọi ma trận và miễn nhiễm với bẫy từ vựng, đổi mới liên tục câu hỏi ép mô hình phải tư duy thay vì học vẹt	Cân bằng hoàn hảo giữa độ nhất quán trong logic và phòng thủ dài hạn mà tối ưu tối đa chi phí vận hành




Chương 3

Phương pháp


GVHD

TS. LƯU THANH SƠN




HybridACD: Giải mã Ràng buộc Đối nghịch
cho Dự báo Mô hình Ngôn ngữ Lớn Nhất quán
về Mặt Logic

BASIC FORECASTER



HYBRIDACD (OUR METHOD)






Chương 4

Kết quả

GVHD

TS. LƯU THANH SƠN




HybridACD: Giải mã Ràng buộc Đối nghịch
cho Dự báo Mô hình Ngôn ngữ Lớn Nhất quán
về Mặt Logic




BASIC FORECASTER


Dataset Scraped: Brier Score vs. Consistency Violation




Dataset NewsAPI: Brier Score vs. Consistency Violation



SO SÁNH BRIER SCORE VÀ VIOLATION SCORE
GIỮA BASIC FORECASTER VÀ HYBRIDACD








DÁNH GIÁ HIỆN TƯỢNG GOODHART



OVERALL EVALUATION

HybridACD vs BasicForecaster: Comprehensive Results Dashboard
(Recent Evaluation vs. ICLR 2025 Baselines)






Chương 5


Kết luận

GVHD

TS. LƯU THANH SƠN





HybridACD: Giải mã Ràng buộc Đối nghịch
cho Dự báo Mô hình Ngôn ngữ Lớn Nhất quán
về Mặt Logic



Kết luận

Hướng phát triển




TỔNG KẾT ĐÓNG GÓP CỦA NGHIÊN CỨU

- TỐI ƯU HOÁ CHI PHÍ VẬN HÀNH (GIẢM TỪ \$2500 CÒN \$0.15 - \$0.5)
- CAN THIỆP GIẢI MÃ THỜI GIAN THỰC: ÉP MÔ HÌNH PHẢI TUÂN THỦ CÁC RẰNG BUỘC TOÀN HỌC
- CAN THIỆP ĐỊNH LUẬT GOODHART
- CÂN BẰNG HIỆU SUẤT



HẠN CHẾ

- HIỆU ỨNG “RÁC ĐẦU VÀO, RÁC HOÀN HẢO ĐẦU RA
- GIỚI HẠN PHẦN CỨNG API VÀ PHẦN MẢNH TOKEN
- LỖ HỔNG TRONG CÁC QUY TẮC KHOẢNG RỘNG



HƯỚNG PHÁT TRIỂN

- CƠ CHẾ KIỂM TRA CHÉO MỎ NEO (CROSS-VALIDATION ANCHOR)
- MỞ RỘNG SANG KHÔNG GIAN DỰ BÁO ĐA BIẾN VÀ LIÊN TỤC
- CHỐT CHẶN AN TOÀN CHO HỆ THỐNG RAG VÀ AGENT




Kết luận HybridACD



Hybrid ACD can thiệp trực tiếp vào tầng giải mã của AI, kết hợp màng lọc toán học và tác tử đối kháng để ép mô hình suy luận tuyệt đối nhất quán logic và không "đoán mò".

Với phương pháp này, hệ thống đã giảm tối đa chi phí vận hành mà vẫn giữ nguyên độ chính xác thực tế và đưa AI dự báo ứng dụng vào thực chiến



HOME

ABOUT

CONTENT

OTHERS



Cảm ơn thầy cô và các bạn
Vì đã lắng nghe

